MAESTRÍA EN GESTIÓN DE TECNOLOGÍAS DE LA INFORMACIÓN

PROPUESTA DE MODELO DE PLATAFORMA DIGITAL CON ANALÍTICA E INTELIGENCIA ARTIFICIAL PARA OPTIMIZAR LA GESTIÓN INFORMACIONAL DE LA CADENA DE SUMINISTRO DE MEDICAMENTOS ESENCIALES EN FARMACIAS SIMAN

CHECKLIST WELL-ARCHITECTED GCP + GUÍA SRE

Objetivo Específico 3: Especificar Arquitectura en la Nube

Información del Instrumento

Estándar	Google Cloud Platform Well-Architected Framework
Proyecto	Modelo de Información con Capacidades Predictivas
Cliente	Farmacias Siman - San Pedro Sula
Fecha	Noviembre 2025
Versión	1.0
Responsable	Gary González Zepeda / Nayra Nicolle Valle Martínez

A. CHECKLIST WELL-ARCHITECTED: RENDIMIENTO

Fuente: Google Cloud Architecture Framework - Performance Efficiency Pillar

ID	Criterio de Rendimiento	Aplicable	Estado	Observaciones
PER-001	Selección apropiada de servicios compute	☑ Sí	✓ Implementado Cloud Run (API inferencia), Vertex AI (entrenamiento ML), Cloud Functions (alertas event-driven)	PER-001
PER-002	Estrategia de caching multicapa (Redis/Memcached)	☐ No	N/A Sin caching adicional (BigQuery con tablas materializadas suficiente para alcance académico)	PER-002
PER-003	Optimización de consultas BigQuery (particionado, clustering)	☑ Sí	✓ Implementado Particionado por fecha_transaccion, clustering por sku + categoria_atc	PER-003
PER-004	Autoescalado configurado (Cloud Run, GKE, Compute Engine)	☑ Sí	✓ Implementado Cloud Run: min=0, max=10 instancias; Vertex AI: auto-scaling habilitado	PER-004
PER-005	CDN habilitado para contenido estático (Cloud CDN)	☐ No	N/A Looker Studio maneja contenido estático internamente	PER-005
PER-006	Compresión de datos en tránsito (gzip, Brotli)	☑ Sí	✓ Implementado TLS 1.3 con compresión	PER-006

			habilitada por defecto en GCP	
PER-007	Balanceadores de carga optimizados por región	☐ No	N/A Una región (us-central1), sin multi-region deployment	PER-007
PER-008	Servicios serverless para cargas variables (Cloud Functions)	☑ Sí	✓ Implementado Cloud Functions para alertas asíncronas vía Pub/Sub	PER-008
PER-009	Pipeline ML optimizado (Vertex AI Pipeline)	☑ Sí	✓ Implementado Vertex AI Training con custom containers, XGBoost optimizado	PER-009
PER-010	Monitoreo de latencia end-to-end configurado	☑ Sí	✓ Implementado Cloud Monitoring con métricas personalizadas p50/p95/p99	PER-010

Métricas Objetivo de Rendimiento:

- **Latencia dashboard:** < 3 segundos
- **Throughput BigQuery:** 1000 QPS
- **Tiempo procesamiento ML:** < 0.08 segundos por fold

B. CHECKLIST WELL-ARCHITECTED: SEGURIDAD

Fuente: Google Cloud Architecture Framework - Security Pillar

ID	Criterio de Seguridad	Aplicable	Estado	Observaciones
SEC-001	IAM con principio de menor privilegio	☑ Sí	✓ Implementado Service Accounts específicos: vertex-ai-sa (solo Vertex AI), bigquery-sa (solo BigQuery read), alertas-sa (solo Pub/Sub publish)	
SEC-002	Service Accounts específicos por servicio	☑ Sí	✓ Implementado Separación completa de roles por servicio GCP	
SEC-003	Cloud KMS para gestión de claves de cifrado	☑ Sí	✓ Implementado Claves CMEK para BigQuery datasets: farmacias_siman_data_key	
SEC-004	Cifrado en reposo habilitado (BigQuery, Cloud Storage)	☑ Sí	✓ Implementado BigQuery: cifrado AES-256 habilitado; GCS: default encryption	
SEC-005	Cifrado en tránsito (TLS 1.2+, HTTPS only)	☑ Sí	✓ Implementado TLS 1.3 forzado en todos los servicios GCP	
SEC-006	VPC con subnets privadas para servicios internos	☑ Sí	✓ Implementado VPC custom mode: subnet-private-ml (10.10.0.0/24) sin IP públicas	

SEC-007	Cloud Armor para protección DDoS y WAF	☐ No	N/A Alcance académico sin exposición pública directa	
SEC-008	Binary Authorization para contenedores (si aplica)	☐ No	N/A Sin GKE, usando servicios serverless	
SEC-009	Cloud Security Command Center habilitado	☑ Sí	✓ Implementado Standard tier con detección de vulnerabilidades activa	
SEC-010	Logs de auditoría configurados (Cloud Audit Logs)	☑ Sí	✓ Implementado Admin Activity, Data Access y System Event logs habilitados	

Controles de Seguridad Específicos:

- **Autenticación:** OAuth 2.0
- **Autorización:** RBAC con IAM policies
- **Datos sensibles:** CONFIDENCIAL
- **Compliance:** ARSA Honduras (CNBS) - Retención 5 años datos transaccionales

C. CHECKLIST WELL-ARCHITECTED: OPERACIÓN

Fuente: Google Cloud Architecture Framework - Operational Excellence Pillar

ID	Criterio de Operación	Aplicable	Estado	Observaciones
OPS-001	Infrastructure as Code (Terraform, Deployment Manager)	☐ No	⚠ Pendiente Deployment manual vía Console por alcance académico. Post-piloto: migrar a Terraform.	OPS-001
OPS-002	CI/CD pipeline automatizado (Cloud Build)	☐ No	⚠ Pendiente Despliegues manuales. Futura implementación con Cloud Build + Git.	OPS-002
OPS-003	Monitoreo unificado (Cloud Monitoring + Alerting)	☑ Sí	✓ Implementado 8 métricas personalizadas configuradas (latencia p95, errores 4xx/5xx, disponibilidad SLO)	OPS-003
OPS-004	Logging centralizado (Cloud Logging + Log Analytics)	☑ Sí	✓ Implementado Logs retention 30 días, filtros por severity≥WARNING	OPS-004
OPS-005	Gestión de configuración centralizada	☑ Sí	✓ Implementado Secret Manager para API keys, Cloud Storage para configs JSON	OPS-005
OPS-006	Estrategia de versionado y rollback	☑ Sí	✓ Implementado Vertex AI Model Registry	OPS-006

			(vSemántico), rollback automático si MAPE>8%	
OPS-007	Documentación técnica automatizada	☐ No	⚠ Pendiente Documentación manual en Google Docs. Futuro: Swagger/OpenAPI para APIs.	OPS-007
OPS-008	Runbooks para incidentes comunes	☑ Sí	✓ Implementado 3 runbooks: (1) MAPE degradado >6%, (2) Latencia dashboard >5s, (3) Error budget agotado	OPS-008
OPS-009	Testing automatizado (unit, integration, e2e)	☐ No	⚠ Pendiente Testing manual. Futura implementación con pytest + Cloud Build.	OPS-009
OPS-010	Disaster recovery plan documentado y probado	☑ Sí	✓ Implementado Backup diario BigQuery → GCS, RPO=24h, RTO=4h (manual restore)	OPS-010

D. GUÍA SRE: SERVICE LEVEL OBJECTIVES (SLO) Y SERVICE LEVEL INDICATORS (SLI)

Fuente: Google Site Reliability Engineering Book

D.1 DEFINICIÓN DE SLIs (Service Level Indicators)

SLI para Sistema de Dashboards:

Aspecto	SLI	Método de Medición	Umbral Objetivo
Disponibilidad	% requests exitosos (HTTP 200)	≥99.0% (successful_requests / total_requests)	Disponibilidad
Latencia	95th percentil tiempo respuesta	< 3 segundos (response_time_95th_percentile)	Latencia
Throughput	Requests por segundo	> 10 RPS (requests_per_second)	Throughput
Exactitud	% datos mostrados correctos	≥95% (correct_data_points / total_data_points)	Exactitud

SLI para Pipeline ML:

Aspecto	SLI	Método de Medición	Umbral Objetivo
Disponibilidad Pipeline	% ejecuciones exitosas	≥99.5% (successful_runs / total_runs)	Disponibilidad Pipeline
Latencia Predicción	Tiempo generación pronóstico	< 5 minutos (prediction_completion_time)	Latencia Predicción

Freshness Datos	Edad datos más recientes	< 24 horas (current_time - latest_data_timestamp)	Freshness Datos
Precisión Modelo	MAPE fuera de muestra	< 6.0% (mean_absolute_percentage_error) [baseline: 3.85%]	Precisión Modelo

D.2 DEFINICIÓN DE SLOs (Service Level Objectives)

SLO DASHBOARD - Período de Medición: 30 días

SLO-001	**Disponibilidad Dashboard**
Descripción	El dashboard estará disponible y funcional
SLI	% requests HTTP 200 exitosos
Objetivo	≥ 99.0% durante período de medición (RNF-003 OE1)
Ventana	30 días rolling
Descripción	El dashboard estará disponible y funcional

SLO PREDICCIÓN - Período de Medición: 7 días

SLO-002	**Latencia Generación Pronósticos**
Descripción	Los pronósticos se generan en tiempo aceptable
SLI	95th percentil tiempo procesamiento
Objetivo	< 5 minutos en 95% de casos (alcanzado: 0.08s por fold XGBoost)
Ventana	7 días rolling
Descripción	Los pronósticos se generan en tiempo aceptable

SLO DATOS - Período de Medición: 24 horas

SLO-003	**Freshness de Datos**
Descripción	Los datos mostrados están actualizados
SLI	Edad máxima datos dashboard
Objetivo	< 24 horas en todo momento (ingesta diaria automatizada)
Ventana	24 horas rolling
Descripción	Los datos mostrados están actualizados

D.3 ERROR BUDGET

Cálculo Error Budget:

SLO	**Objetivo**	**Error Budget (30 días)**	**Tiempo Permitido Indisponibilidad**
Disponibilidad Dashboard (99%)	99.0%	1.0%	7.2 horas/mes (RNF-003)
Disponibilidad ML Pipeline (99.5%)	99.5%	0.5%	3.6 horas/mes
Disponibilidad Almacenamiento (99.9%)	99.9%	0.1%	43 minutos/mes

Políticas Error Budget:

Estado Error Budget	**Acción**	**Responsable**

> 50% restante	Operación normal, despliegues permitidos	Jefe Farmacia + Equipo técnico
25-50% restante	Revisión semanal, despliegues con aprobación	Jefe Farmacia (aprobación obligatoria)
10-25% restante	Revisión diaria, stop features nuevas	Equipo técnico (freeze deployments)
< 10% restante	Modo conservación, solo bugfixes críticos	Escalación a asesor técnico UNITEC
Agotado (0%)	Halt completo despliegues hasta recuperación	Revisión post-mortem obligatoria

D.4 ALERTAS Y ESCALACIÓN

Configuración de Alertas:

Tipo Alerta	Condición	Severidad	Canal	Tiempo Respuesta
SLO Breach	SLI < umbral SLO	Crítica	Email + Slack (futuro)	< 15 min
Error Budget < 10% restante	Budget agotándose	Warning	Email	< 30 min
Latencia Alta	p95 > 5s dashboard	Warning	Email	< 30 min
Disponibilidad < 99%	Uptime < 99% por > 10 min	Crítica	Email + SMS (futuro)	< 10 min

---

Leyenda:

- ✓ = Implementado y funcionando
- ⚠ = Implementado parcialmente o requiere mejoras
- ✗ = No implementado
- **N/A** = No aplicable al contexto actual